

1 Objetivos

- Investigar sobre los ataques de evasión, inferencia, extracción y envenenamiento
- Utilizar el framework Adversarial Robustness ToolBox para atacar modelos de ML y DL

2 Preámbulo

Seguridad en modelos de data science

Los modelos de machine learning y deep learning son activos que están sujetos a los ciberataques, como cualquier otro activo digital.

Los ataques varían según su propósito y clasificación. En los ataques de caja negra, el adversario no conoce los detalles de implementación del modelo, en tanto que, en los ataques de caja blanca, el adversario si conoce los detalles.

Ataques de extracción

Las empresas que utilizan ML/DL para apoyar sus procesos de negocio invierten una gran cantidad de recursos en la investigación, desarrollo e implementación de sus modelos, y luego ofrecen un servicio pagado de clasificación a través de una API, por ejemplo.

Con esta información, se puede realizar un ataque de caja negra/blanca que consiste en utilizar un dataset y obtener la clasificación y confianza a través de la API. Aun si utilizar la API tiene un costo, este será mínimo en comparación con los resultados. La idea es obtener las etiquetas y confianza para cada una de las observaciones, y con ello, ¡entrenar un modelo propio! (Ataque de extracción).


Dado que el nuevo modelo se entrenará en la forma en que el modelo objetivo clasifica, este tendrá resultados muy similares, sin invertir la gran cantidad de recursos que el modelo original.

Ataques de inferencia

Muchos modelos son entrenados con una combinación de datasets públicos y privados. Un atacante puede crear un modelo que permita saber si un registro fue utilizado como parte del entrenamiento (Membership). Un atacante también puede inferir data de un modelo a partir de indicar la clase buscada.

Ataques de evasión

Generative Adversarial Networks (GANs) son una forma de construir un modelo generativo al tener dos redes neuronales compitiendo una contra otra.



Una red toma el papel del generador (**G**), que convierte ruido aleatorio en imitaciones de data, intentando engañar al discriminador.

La otra red toma el papel del discriminador (**D**), que trata de distinguir data real de data falsa creada por el generador. Esto se puede aprovechar para realizar ataques con data que engañen a los modelos de clasificación.

Ataque de envenenamiento

Se aprovecha de la debilidad del entrenamiento federado, pues los nodos locales no siempre toman medidas de seguridad para asegurar la confiabilidad de sus fuentes de datos. La versión más peligrosa de este ataque es un backdoor, pues confunde al modelo únicamente para un patrón específico, y es muy difícil de detectar.

3 Desarrollo

El laboratorio consiste en el desarrollo de dos ataques (de diferente categoría), utilizando el framework Adversarial Robustness ToolBox, originalmente desarrollador por IBM, y donado recientemente a The Linux Foundation.

<https://adversarial-robustness-toolbox.org/>

Este framework contiene módulos de ataque y defensa, métricas, etc; y soporta frameworks como TensorFlow, Keras, Scikit-Learn, PyTorch, etc., todo tipo de data (imágenes, tablas, video, etc.) y tareas de machine learning (clasificación, generación, etc.)

El modelo objetivo del ataque será el modelo desarrollado en el laboratorio #6 – Clasificación de malware con DL.

Sugerencia: instalar el ART framework y probar los ejemplos vistos en clase, antes de realizar los ataques sobre el modelo del laboratorio 6, para asegurar que la herramienta fue instalada correctamente y que funciona sin problemas.

4 Calificación

- El grupo de trabajo será el mismo grupo que trabajó el laboratorio #6 – Clasificación de malware con DL.
 - Se debe entregar el link al repositorio en Github del laboratorio que debe incluir:
 - Jupyter Notebook: explicación de los ataques elegidos, evidencia de los pasos realizados y prueba del ataque en el modelo del laboratorio #6.
- La fecha de entrega será el martes **9 de mayo a las 17:20 horas**.
- Plagio parcial o total anula el proyecto, y se elevará el caso a la Dirección para las sanciones administrativas.